

# “摩拜” 需要我

# 今日内容

- 神经网络预测器1
  - 神经元细胞
  - 神经网络
  - 神经网络的工作原理
- 神经网络预测器2
  - 数据预处理
  - 利用pytorch构建神经网络
  - 预测结果及其分析
- 对神经网络的解剖
- 神经网络分类器
- 附带视频
  - 神经网络与反向传播算法的数学原理

## 共享单车热遍全国



## 摩拜的苦恼



- 问题引出:
  - 究竟什么时间派送工人去搬运
  - 应该从哪里搬运到哪里?
  - 应该搬运多少辆单车?



# 摩拜的苦恼




## 单车预测器

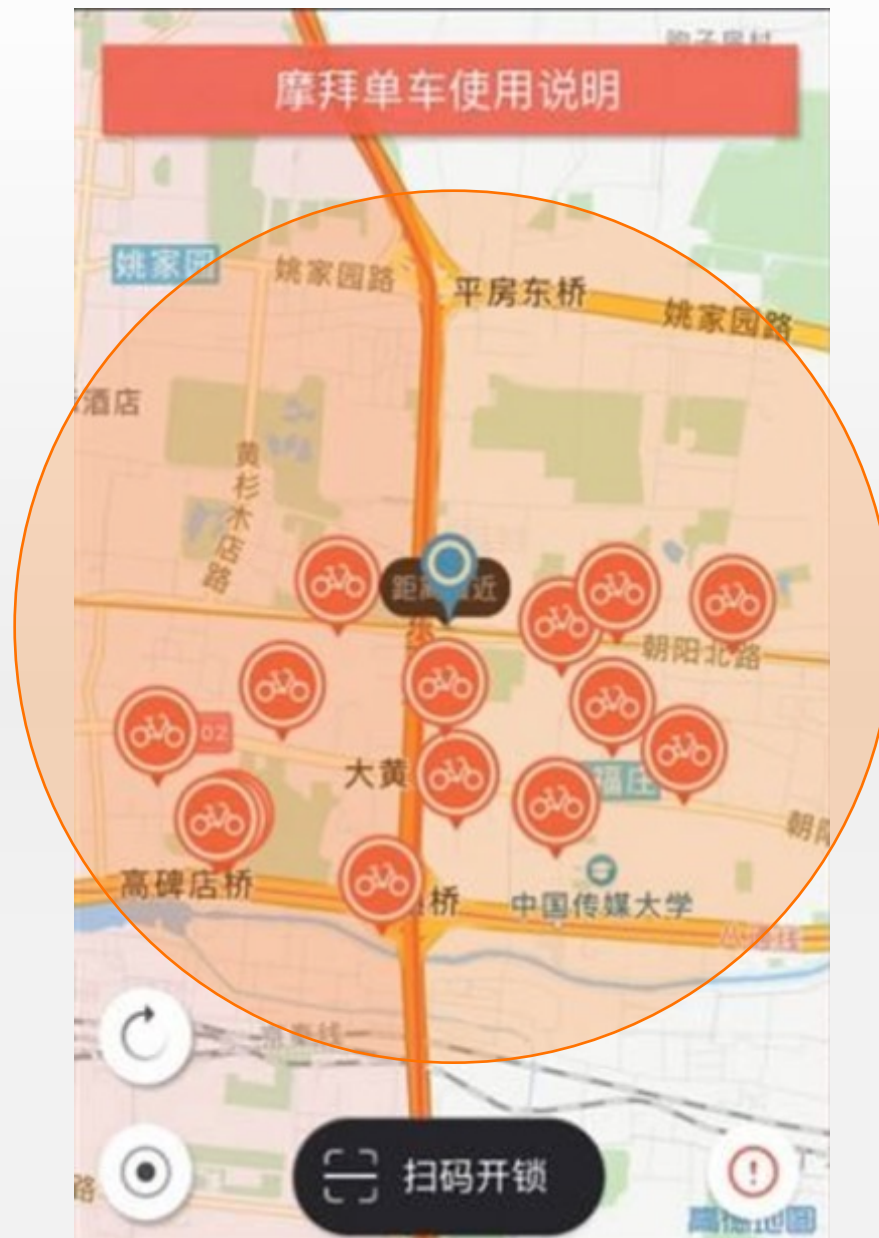
### • 问题引出:

- 究竟什么时间派送工人去搬运
- 应该从哪里搬运到哪里?
- 应该搬运多少辆单车?

# 单车预测问题




- 预测未来的曲线?




# 数据来源

<http://capitalbikeshare.com/system-data>

<http://www.freemeteo.com>




# 线性回归



找到一条直线，使得它到所有点的距离都很小




# 线性回归



找到一条直线，使得它到所有点的距离都很小

$$L = \frac{1}{N} \sum_{i=1}^N (aX_i + b - Y_i)^2$$

# 线性回归




找到一条直线，使得它到所有点的距离都很小

$$L = \frac{1}{N} \sum_{i=1}^N (aX_i + b - Y_i)^2$$

$$\min_{a,b} L(a,b)$$

# 线性回归



找到一条直线，使得它到所有点的距离都很小

$$L = \frac{1}{N} \sum_{i=1}^N (aX_i + b - Y_i)^2$$



计算梯度：  $\frac{\partial L}{\partial a}, \frac{\partial L}{\partial b}$

梯度下降算法：



$$a_{t+1} = a_t - \alpha \cdot \frac{\partial L}{\partial a}$$

$$b_{t+1} = b_t - \alpha \cdot \frac{\partial L}{\partial b}$$

# 简单神经网络预测器




# 简单神经网络预测器







# 单个神经元




$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$



# 单个神经元




$$\sigma(x) = \frac{1}{1 + \exp(-wx)}$$




$w$ 控制着曲线的弯曲程度

# 单个神经元




$$\sigma(x) = \frac{1}{1 + \exp(-(wx + b))}$$




$b$ 控制着曲线的竖直位置

# 单个神经元




$$\sigma(x) = \frac{w'}{1 + \exp(-w(x+b))}$$



$w'$ 控制着曲线的高矮


# 两个神经元



$$y = w'_1 \sigma(w_1 x + b_1) + w'_2 \sigma(w_2 x + b_2)$$




# 两个神经元




$$y = w'_1 \sigma(w_1 x + b_1) + w'_2 \sigma(w_2 x + b_2)$$

$$\sigma_1(x) = \frac{1}{1 + \exp(-(x + 1))} \quad \sigma_2(x) = \frac{1}{1 + \exp(-x)}$$




$b$ 控制着曲线的竖直位置

# 两个神经元




$$y = w'_1 \sigma(w_1 x + b_1) + w'_2 \sigma(w_2 x + b_2)$$

$$y = \frac{1}{1 + \exp(-(x + 1))} + \frac{1}{1 + \exp(-x)}$$




$b$ 控制着曲线的竖直位置

# 两个神经元




$$y = w'_1 \sigma(w_1 x + b_1) + w'_2 \sigma(w_2 x + b_2)$$

$$y = \frac{1}{1 + \exp(-x)} + \frac{-1}{1 + \exp(-x + 1)}$$




$b$ 控制着曲线的竖直位置

# 两个神经元





$$y = w'_1 \sigma(w_1 x + b_1) + w'_2 \sigma(w_2 x + b_2)$$

$$y = \frac{1}{1 + \exp(-x)} + \frac{-1}{1 + \exp(-x + 1)}$$




$b$ 控制着曲线的竖直位置

# 我们至少需要多少隐含层神经元？





# 第一个单隐含层神经网络



# 导入需要的库

In [1]:

```
#导入需要使用的库
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import torch
from torch.autograd import Variable

# 让输出的图形直接在Notebook中显示
%matplotlib inline
```

导入、处理csv文件的库

有关Tensor操作的torch库  
用于autograd自动求导变量的库

# 导入数据

In [2]:

```
#读取数据到内存中，rides为一个dataframe对象
data_path = 'Bike-Sharing-Dataset/hour.csv'
rides = pd.read_csv(data_path)
#看看数据长什么样子
rides.head()
```

导入、处理csv文件的库

显示前几条记录

Out[2]:

	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
0	1	2011-01-01	1	0	1	0	0	6	0	1	0.24	0.2879	0.81	0.0	3	13	16
1	2	2011-01-01	1	0	1	1	0	6	0	1	0.22	0.2727	0.80	0.0	8	32	40
2	3	2011-01-01	1	0	1	2	0	6	0	1	0.22	0.2727	0.80	0.0	5	27	32
3	4	2011-01-01	1	0	1	3	0	6	0	1	0.24	0.2879	0.75	0.0	3	10	13
4	5	2011-01-01	1	0	1	4	0	6	0	1	0.24	0.2879	0.75	0.0	0	1	1

# 初始化神经网络权重等变量

```
In [3]: counts = rides['cnt'][:50]
x = Variable(torch.FloatTensor(np.arange(len(counts), dtype = float)/len(counts)))
y = Variable(torch.FloatTensor(np.array(counts, dtype = float)))
sz = 10
# 初始化所有神经网络的权重 (weights) 和阈值 (biases)
weights = Variable(torch.randn(1, sz), requires_grad = True)
biases = Variable(torch.randn(sz), requires_grad = True)
weights2 = Variable(torch.randn(sz, 1), requires_grad = True)
```

提取数据库的cnt字段前50条记录


50行1列

50行1列

1行10列

10个元素的列向量

10行1列



## 神经网络梯度下降迭代

In [4]:

```
learning_rate = 0.0001 #设置学习率
losses = []
for i in range(1000000):
    # 从输入层到隐含层的计算
    hidden = x.expand(sz, len(x)).t() * weights.expand(len(x), sz) + biases.expand(len(x), sz)
    # 将sigmoid函数作用在隐含层的每一个神经元上
    hidden = torch.sigmoid(hidden)
    # 隐含层输出到输出层，计算得到最终预测
    predictions = hidden.mm(weights2)
    # 通过与标签数据y比较，计算误差
    loss = torch.mean((predictions - y) ** 2)
    if i % 10000 == 0:
        print('loss:', loss)
    loss.backward() #对损失函数进行梯度反传
    #利用上一步计算中得到的weights, biases等梯度信息更新weights或biases中的data数值
    weights.data.add_(- learning_rate * weights.grad.data)
    biases.data.add_(- learning_rate * biases.grad.data)
    weights2.data.add_(- learning_rate * weights2.grad.data)
    # 梯度清空
    weights.grad.data.zero_()
    biases.grad.data.zero_()
    weights2.grad.data.zero_()
```



# 神经网络梯度下降迭代

In [4]:

```
learning_rate = 0.0001 #设置学习率
losses = []
for i in range(1000000):
```

```
    # 从输入层到隐含层的计算
```

```
    hidden = x.expand(sz, len(x)).t() * weights.expand(len(x), sz) + biases.expand(len(x), sz)
```

```
    # 将sigmoid函数作用在隐含层的每一个神经元上
```


```
    hidden = torch.sigmoid(hidden)
```

```
    # 隐含层输出到输出层，计算得到最终预测
```

```
    predictions = hidden.mm(weights2) + biases2.expand_as(y)
```

```
    # 通过与标签数据y比较，计算误差
```

```
    loss = torch.nn.Loss(x, ( 0.1 3 0.2, ..., 3))
```



$$\begin{pmatrix} 0.1 & 0.1 & 0.1 \dots & 0.1 & 0.1 & 0.1 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ \vdots & \vdots & \vdots \dots & \vdots & \vdots & \vdots \\ 1.0 & 1.0 & 1.0 & 1.0 & 1.0 & 1.0 \end{pmatrix}$$

10\*50

```
    losses.append(loss.data.numpy())
```

```
    if i % 10000 == 0:
```

```
        print('loss:', loss)
```

```
    loss.backward() #对损失函数进行梯度反传
```

```
    #利用上一步计算中得到的weights, biases等梯度信息更新weights或biases中的data数值
```

```
    weights.data.add_(- learning_rate * weights.grad.data)
```

```
    biases.data.add_(- learning_rate * biases.grad.data)
```

```
    weights2.data.add_(- learning_rate * weights2.grad.data)
```

```
    biases2.data.add_(- learning_rate * biases2.grad.data)
```

# 神经网络梯度下降迭代

In [4]:

```
learning_rate = 0.0001 #设置学习率
losses = []
for i in range(1000000):
```

# 从输入层到隐含层的计算

```
hidden = x.expand(sz, len(x)).t() * weights.expand(len(x), sz) + biases.expand(len(x), sz)
```

# 将sigmoid函数作用在隐含层的每一个神经元上

```
hidden = torch.sigmoid(hidden)
```

# 隐含层输出到输出层，计算得到最终预测

```
predictions = hidden.mm(weights2) + biases2.expand_as(y)
```

# 通过与标签数据y比较，计算误差

```
loss = torch.nn.Loss(x, predictions)
```

```
losses.append(loss.data.numpy())
```

```
if i % 10000 == 0:
```

```
    print('loss:', loss)
```

```
loss.backward() #对损失函数进行梯度反传
```

#利用上一步计算中得到的weights, biases等梯度信息更新weights或biases中的data数值

```
weights.data.add_(- learning_rate * weights.grad.data)
```

```
biases.data.add_(- learning_rate * biases.grad.data)
```

```
weights2.data.add_(- learning_rate * weights2.grad.data)
```

```
biases2.data.add_(- learning_rate * biases2.grad.data)
```

expand

$$\begin{pmatrix} 0.1 & 0.1 & 0.1 & \dots & 0.1 & 0.1 & 0.1 \\ 0.2 & 0.2 & 0.2 & & 0.2 & 0.2 & 0.2 \\ \vdots & \vdots & \vdots & \dots & \vdots & \vdots & \vdots \\ 1.0 & 1.0 & 1.0 & & 1.0 & 1.0 & 1.0 \end{pmatrix}$$

10\*50

expand

$$\begin{pmatrix} 0.2 & 3 & & 0.1 \\ 0.2 & 3 & & 0.1 \\ \vdots & \vdots & \dots & \vdots \\ 0.2 & 3 & & 0.1 \end{pmatrix}$$

50\*10

weights (0.2 3 ... 0.1)

# 神经网络梯度下降迭代

In [4]:

```
learning_rate = 0.0001 #设置学习率
```

```
losses = []
```

```
for i in range(1000000):
```

```
    # 从输入层到隐含层的计算
```

```
    hidden = torch.t(x.expand(sz, len(x))) * weights.expand(len(x), sz) + biases.expand(len(x), sz)
```

```
    # 将sigmoid函数作用在隐含层的每一个神经元上
```

```
    hidden = torch.sigmoid(hidden)
```

```
    # 隐含层输出到输出层，计算得到最终预测
```

```
    predictions = hidden.mm(weights2)
```

```
    # 通过与标签数据y比较，计算误差
```

```
    loss = torch.mean((predictions - y) ** 2)
```

```
    losses.append(loss.data.numpy())
```

```
    if i % 100000 == 0:
```

```
        print('Iteration %d, Loss: %f' % (i, loss.data.numpy()))
```

```
        loss.backward()
```

```
        # 利用上一步计算中得到的weights, biases等梯度信息
```

```
        weights.data.add_(- learning_rate * weights.grad.data)
```

```
        biases.data.add_(- learning_rate * biases.grad.data)
```

```
        weights2.data.add_(- learning_rate * weights2.grad.data)
```

```
        biases2.data.add_(- learning_rate * biases2.grad.data)
```

$$\begin{pmatrix} 0.1 & 0.1 & 0.1 & \dots & 0.1 & 0.1 & 0.1 \\ 0.2 & 0.2 & 0.2 & & 0.2 & 0.2 & 0.2 \\ \vdots & \vdots & \vdots & \dots & \vdots & \vdots & \vdots \\ 1.0 & 1.0 & 1.0 & & 1.0 & 1.0 & 1.0 \end{pmatrix}$$

mm



$$\begin{pmatrix} 7.1 \\ -0.2 \\ 2 \\ 1.1 \\ \vdots \\ 1.0 \end{pmatrix}$$

=

$$\begin{pmatrix} 0.71 \\ -0.02 \\ 0.2 \\ 0.11 \\ \vdots \\ 0.10 \end{pmatrix}$$

data数值

# 拟合结果



# 预测代码

```
In [5]: counts_predict = rides['cnt'][50:100]#读取待预测的接下来的50个数据点

#首先对接下来的50个数据点进行选取，注意x应该取51, 52, ....., 100，然后再归一化
x = Variable(torch.FloatTensor((np.arange(len(counts_predict), dtype = float) + len(counts)) / len(counts_predict)))

#读取下50个点的y数值
y = Variable(torch.FloatTensor(np.array(counts_predict, dtype = float)))


# 从输入层到隐含层的计算
hidden = x.expand(sz, len(x)).t() * weights.expand(len(x), sz)

# 将sigmoid函数作用在隐含层的每一个神经元上
hidden = torch.sigmoid(hidden)

# 隐含层输出到输出层，计算得到最终预测
predictions = hidden.mm(weights2)

# 计算预测数据上的损失函数
loss = torch.mean((predictions - y) ** 2)
print(loss)
```

# 预测结果



Loss: 6250.5

# 存在问题

- 存在着严重的过拟合现象
- 采用单一属性（编号）预测未来单车数量效果太差
  - 事实上，单车使用数量和下标之间根本就没有关系!!!
- 运行速度缓慢
- 需要考虑其它可获得信息：是否工作日、天气情况：风速湿度等

# 接下来，你将会学到

- 如何设计一个多输入的神经网络
- 如何对数据进行预处理
- 如何以及为什么对数据分撮 (Batch)
- 如何用pytorch简化神经网络构建流程



## 再来看看数据

<http://capitalbikeshare.com/system-data>

<http://www.freemeteo.com>

编号

## 季节

月

是否假期

是否工作日

温度

湿度

出行数量

	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	cnt
0	1	2011/1/1	1	0	1	0	0	6	0	1	0.24	0.2879	0.81	0.0	16
1	2	2011/1/1	1	0	1	1	0	6	0	1	0.22	0.2727	0.80	0.0	40
2	3	2011/1/1	1	0	1	2	0	6	0	1	0.22	0.2727	0.80	0.0	32
3	4	2011/1/1	1	0	1	3	0	6	0	1	0.24	0.2879	0.75	0.0	13
4	5	2011/1/1	1	0	1	4	0	6	0	1	0.24	0.2879	0.75	0.0	1

日期

年

小时

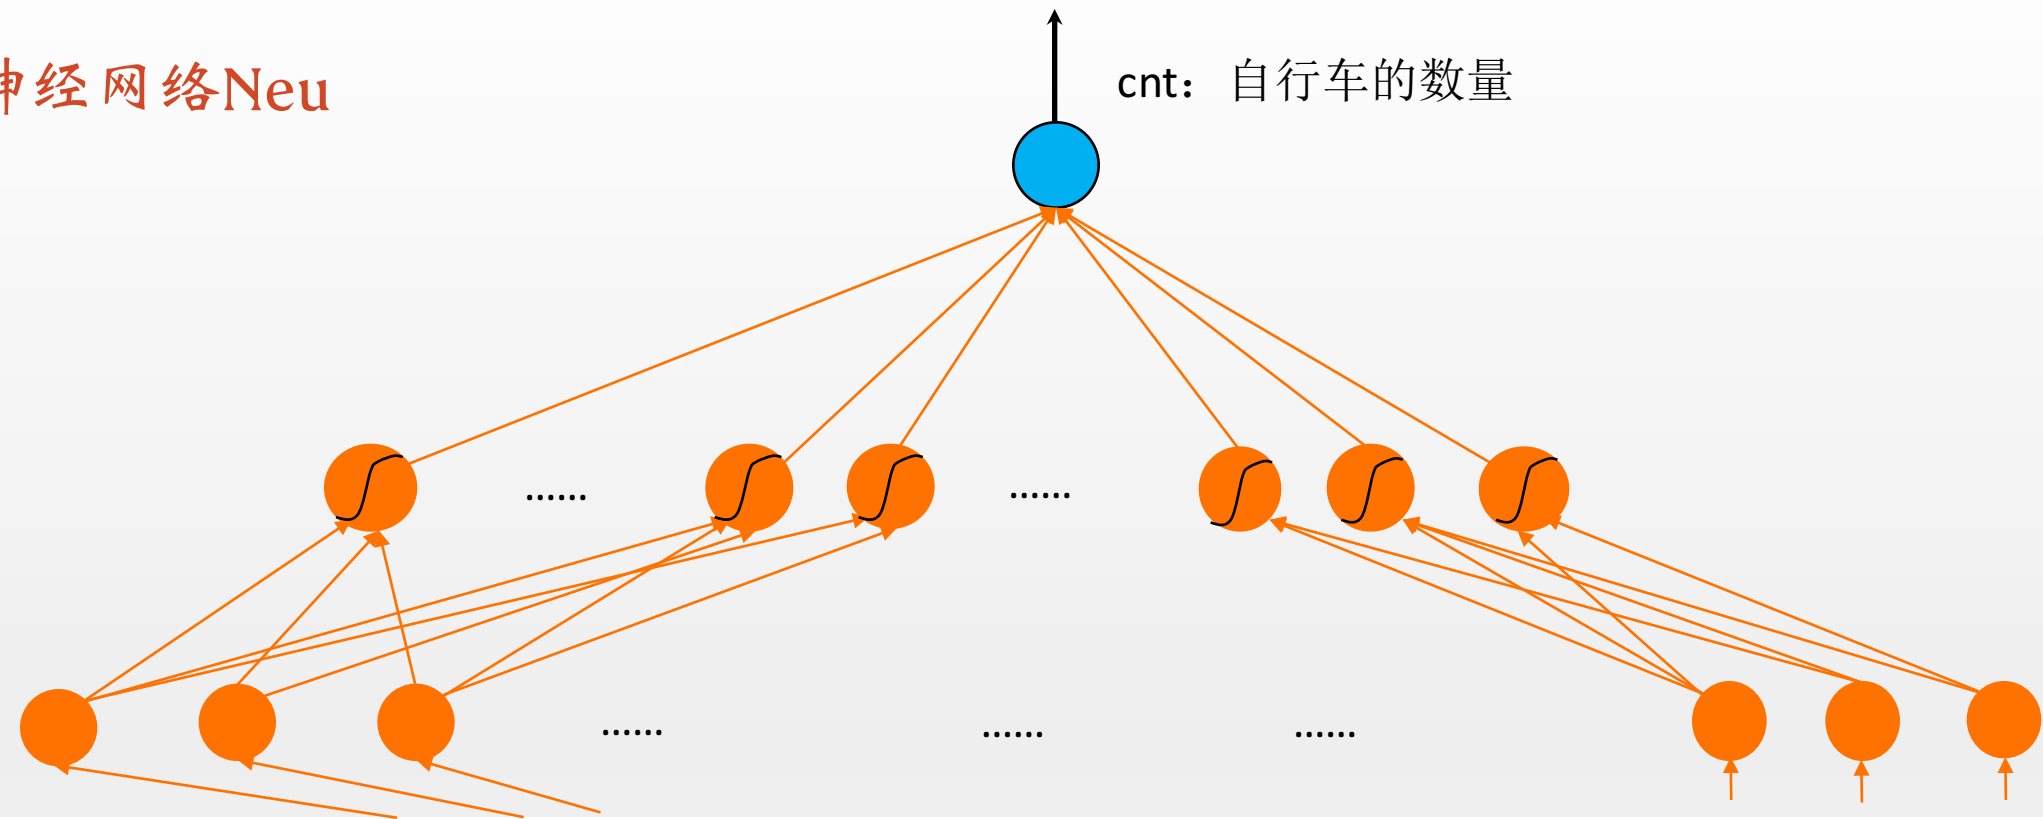
星期几

天气，1  
晴，2  
雾.....

体表  
温度



风速

神经网络Neu





	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	cnt
0	1	2011/1/1	1	0	1	0	0	6	0	1	0.24	0.2879	0.81	0.0	16
1	2	2011/1/1	1	0	1	1	0	6	0	1	0.22	0.2727	0.80	0.0	40
2	3	2011/1/1	1	0	1	2	0	6	0	1	0.22	0.2727	0.80	0.0	32
3	4	2011/1/1	1	0	1	3	0	6	0	1	0.24	0.2879	0.75	0.0	13
4	5	2011/1/1	1	0	1	4	0	6	0	1	0.24	0.2879	0.75	0.0	1

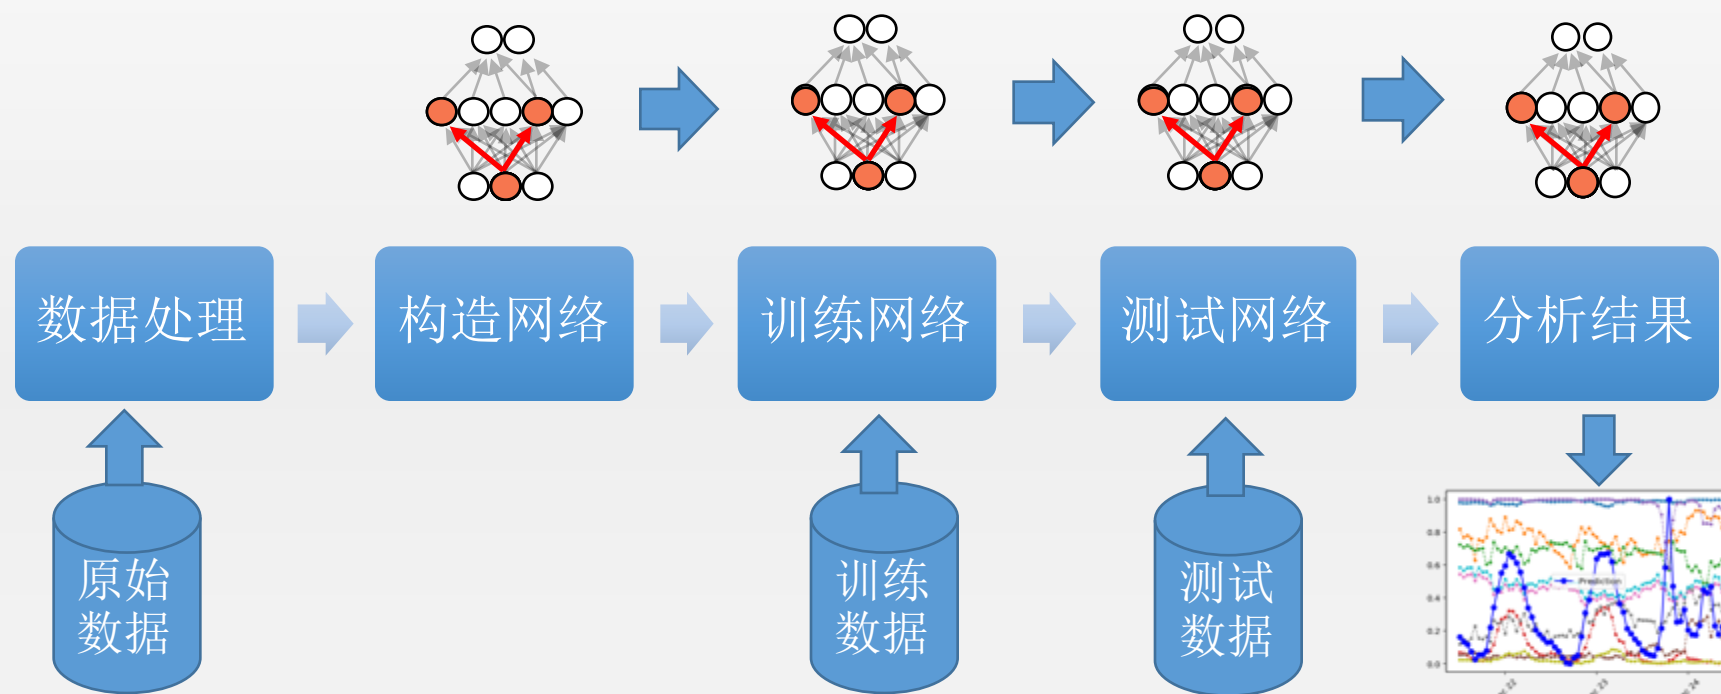
# 两个预测问题的对比



# 两个神经网络的对比



# 数据准备



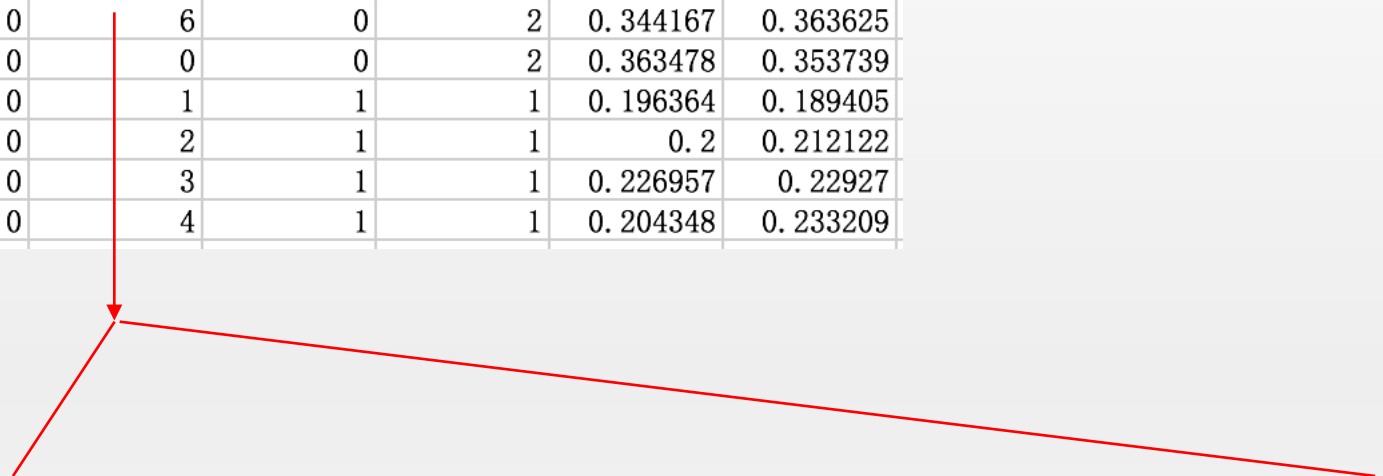
# 数据预处理： 类型变量

- 类型数据的处理
- Weekday: 1, 2, 3, 4, 5, 6, 0

星期	类型变量	类型编码
星期日	0	1 0 0 0 0 0 0
星期一	1	0 1 0 0 0 0 0
星期二	2	0 0 1 0 0 0 0
星期三	3	0 0 0 1 0 0 0
星期四	4	0 0 0 0 1 0 0
星期五	5	0 0 0 0 0 1 0
星期六	6	0 0 0 0 0 0 1

# 数据预处理： 类型变量

	holiday	weekday	workingday	weathersit	temp	atemp
1	0	6	0	2	0.344167	0.363625
1	0	0	0	2	0.363478	0.353739
1	0	1	1	1	0.196364	0.189405
1	0	2	1	1	0.2	0.212122
1	0	3	1	1	0.226957	0.22927
1	0	4	1	1	0.204348	0.233209




hr_23	weekday_0	weekday_1	weekday_2	weekday_3	weekday_4	weekday_5	weekday_6
0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	1

One-hot编码


将一个变量扩展为n个变量，n为类型数目

# 数据预处理：数值类型变量归一化

temp	atemp	hum
0.24	0.2879	0.81
0.22	0.2727	0.80
0.22	0.2727	0.80
0.24	0.2879	0.75
0.24	0.2879	0.75



$$\frac{X - \bar{X}}{\sigma(X)}$$





# 数据准备

数据集




2011-1-1

2012-12-31

# 数据准备



# 将数据分撮处理



- 如何训练？
  - 将训练切割成小的撮 (batch)
  - 对每一个小撮进行误差计算、反向传播，调整权重


# 建立神经网络

```
input_size = features.shape[1]
output_size = 1
weights1 = Variable(torch.randn([input_size, hidden_size]), requires_grad = True)

biases = Variable(torch.randn([hidden_size]), requires_grad = True)


weights2 = Variable(torch.randn([hidden_size, output_size]), requires_grad = True)
```

- 定义一个 $\text{input\_size} \times \text{sz}$ 的第一层权重矩阵
- 定义一个 $\text{sz}$ 尺度的向量biases
- 定义一个 $\text{sz} \times 1$ 的第二层权重矩阵



# 建立神经网络

```
neu= torch.nn.Sequential(  
    torch.nn.Linear(input_size, hidden_size),  
    torch.nn.Sigmoid(),  
    torch.nn.Linear(hidden_size, output_size),  
)
```



- 建立一个多步操作的神经网络模型
- 第一步从输入层到隐含层节点为一个线性运算，输入维度`input_size`，隐含维度`hidden_size`
- 第二步为Sigmoid，作用到每一个隐含层神经元上
- 第三步又是一个线性运算，从隐含到输出，神经元个数分别为`hidden_size`和`output_size`
- 所有神经网络的参数都存储在`neu.parameters()`里面了

# 建立损失函数和优化器

```
cost = torch.nn.MSELoss()  
optimizer = torch.optim.SGD(neu.parameters(), lr = 0.01)
```

- `torch.nn.MSELoss()` 等价于函数 `torch.mean((x-y)^2)`
- `torch.optim.SGD(neu.parameters(), lr = 0.01)`
  - `neu.parameters()` 返回神经网络 `neu` 的所有权重、偏置参数
  - 建立一个随机梯度下降优化器，它可以代替 `parameters.data.add_(lr * parameters.grad.data)`

# 主要训练循环

```
# 神经网络训练循环
for i in range(2000):
    batch_loss = [] #记录每一个撮的损失
    # 每128个样本点被划分为一个撮
    # start和end分别是提取一个batch数据的起始和终止下标
    for start in range(0, len(X), batch_size):
        end = start + batch_size if start + batch_size < len(X) else len(X)
        xx = Variable(torch.FloatTensor(X[start:end]))
        yy = Variable(torch.FloatTensor(Y[start:end]))
        predict = neu(xx) # 模型预测
        loss = cost(predict, yy) # 计算损失函数（均方误差）
        optimizer.zero_grad() # 将优化器存储的那些参数的梯度设置为0
        loss.backward() # 开始反向传播，计算所有梯度值
        optimizer.step() # 优化器开始运行一步，更新所有的参数
        batch_loss.append(loss.data.numpy())
    # 每隔100步输出一下损失值（loss）
    if i % 100 == 0:
        losses.append(np.mean(batch_loss))
        print(i, np.mean(batch_loss))
```

# 主要训练循环

```
# 神经网络训练循环
```

```
for i in range(2000):
```

```
    batch_loss = [] #记录每一个撮的损失
```

```
    # 每128个样本点被划分为一个撮
```

```
    # start和end分别是提取一个batch数据的起始和终止下标
```

```
    for start in range(0, len(X), batch_size):
```

```
        end = start + batch_size if start + batch_size < len(X) else len(X)
```

```
        xx = Variable(torch.FloatTensor(X[start:end]))
```

```
        yy = Variable(torch.FloatTensor(Y[start:end]))
```

```
        predict = neu(xx) # 模型 hidden = x.expand(sz, len(x)).t() * weights.expand(len(x), sz) + biases.expand(len(x), sz)
```

```
        loss = cost(predict, yy) # hidden = torch.sigmoid(hidden)
```

```
        optimizer.zero_grad() # predictions = hidden.mm(weights2)
```

```
        loss.backward() # 开始反向传播, 计算所有梯度值
```

```
        optimizer.step() # 优化器开始运行一步, 更新所有的参数
```

```
        batch_loss.append(loss.data.numpy())
```

```
    # 每隔100步输出一下损失值 (loss)
```

```
    if i % 100 == 0:
```

```
        losses.append(np.mean(batch_loss))
```

```
        print(i, np.mean(batch_loss))
```



# 主要训练循环

```
# 神经网络训练循环
for i in range(2000):
    batch_loss = [] #记录每一个撮的损失
    # 每128个样本点被划分为一个撮
    # start和end分别是提取一个batch数据的起始和终止下标
    for start in range(0, len(X), batch_size):
        end = start + batch_size if start + batch_size < len(X) else len(X)
        xx = Variable(torch.FloatTensor(X[start:end]))
        yy = Variable(torch.FloatTensor(Y[start:end]))
        predict = neu(xx) # 模型预测
        loss = cost(predict, yy) # 计算
        optimizer.zero_grad() # 将optimizer中的参数梯度清零
        loss.backward() # 开始反向传播
        optimizer.step() # 优化器开始运行一步，更新所有的参数
        batch_loss.append(loss.data.numpy())
    # 每隔100步输出一下损失值（loss）
    if i % 100 == 0:
        losses.append(np.mean(batch_loss))
        print(i, np.mean(batch_loss))
```

# 主要训练循环

# 神经网络训练循环

for i in range(2000):

batch\_loss = [] #记录每一个撮的损失

# 每128个样本点被划分为一个撮

# start和end分别是提取一个batch数据的起始和终止下标

for start in range(0, len(X), batch\_size):

end = start + batch\_size if start + batch\_size < len(X) else len(X)

xx = Variable(torch.FloatTensor(X[start:end]))

yy = Variable(torch.FloatTensor(Y[start:end]))

predict = neu(xx) # 模型预测

loss = cost(predict, yy) # 计算损失函数（均方误差）

optimizer.zero\_grad() # 将优化器存储的那些参数的梯度设置为0

loss.backward() # 开始反向传播，计算所有梯度值

optimizer.step() # 优化器更新参数

batch\_loss.append(loss.data)

weights.data.add\_(- learning\_rate \* weights.grad.data)

biases.data.add\_(- learning\_rate \* biases.grad.data)

weights2.data.add\_(- learning\_rate \* weights2.grad.data)



# 每隔100步输出一下损失

if i % 100 == 0:


losses.append(np.mean(batch\_loss))

print(i, np.mean(batch\_loss))


# 运行结果



# 解剖神经网络





# 对Neu进行诊断





```
def feature(X, net):  
    X = Variable(torch.from_numpy(X).type(torch.FloatTensor),  
requires_grad = False)  
    dic = dict(net.named_parameters())  
    weights = dic['0.weight']  
    biases = dic['0.bias']  
    h = torch.sigmoid(X.mm(weights.t()) + biases.expand([len(X),  
len(biases)]))  
    return h
```



# 对Neu进行诊断



# 解剖Neu





# 解剖Neu







# 解剖Neu





weathersit\_3  
雨雪雷电

Hr\_6  
早6点

# 解剖Neu





# 解剖Neu



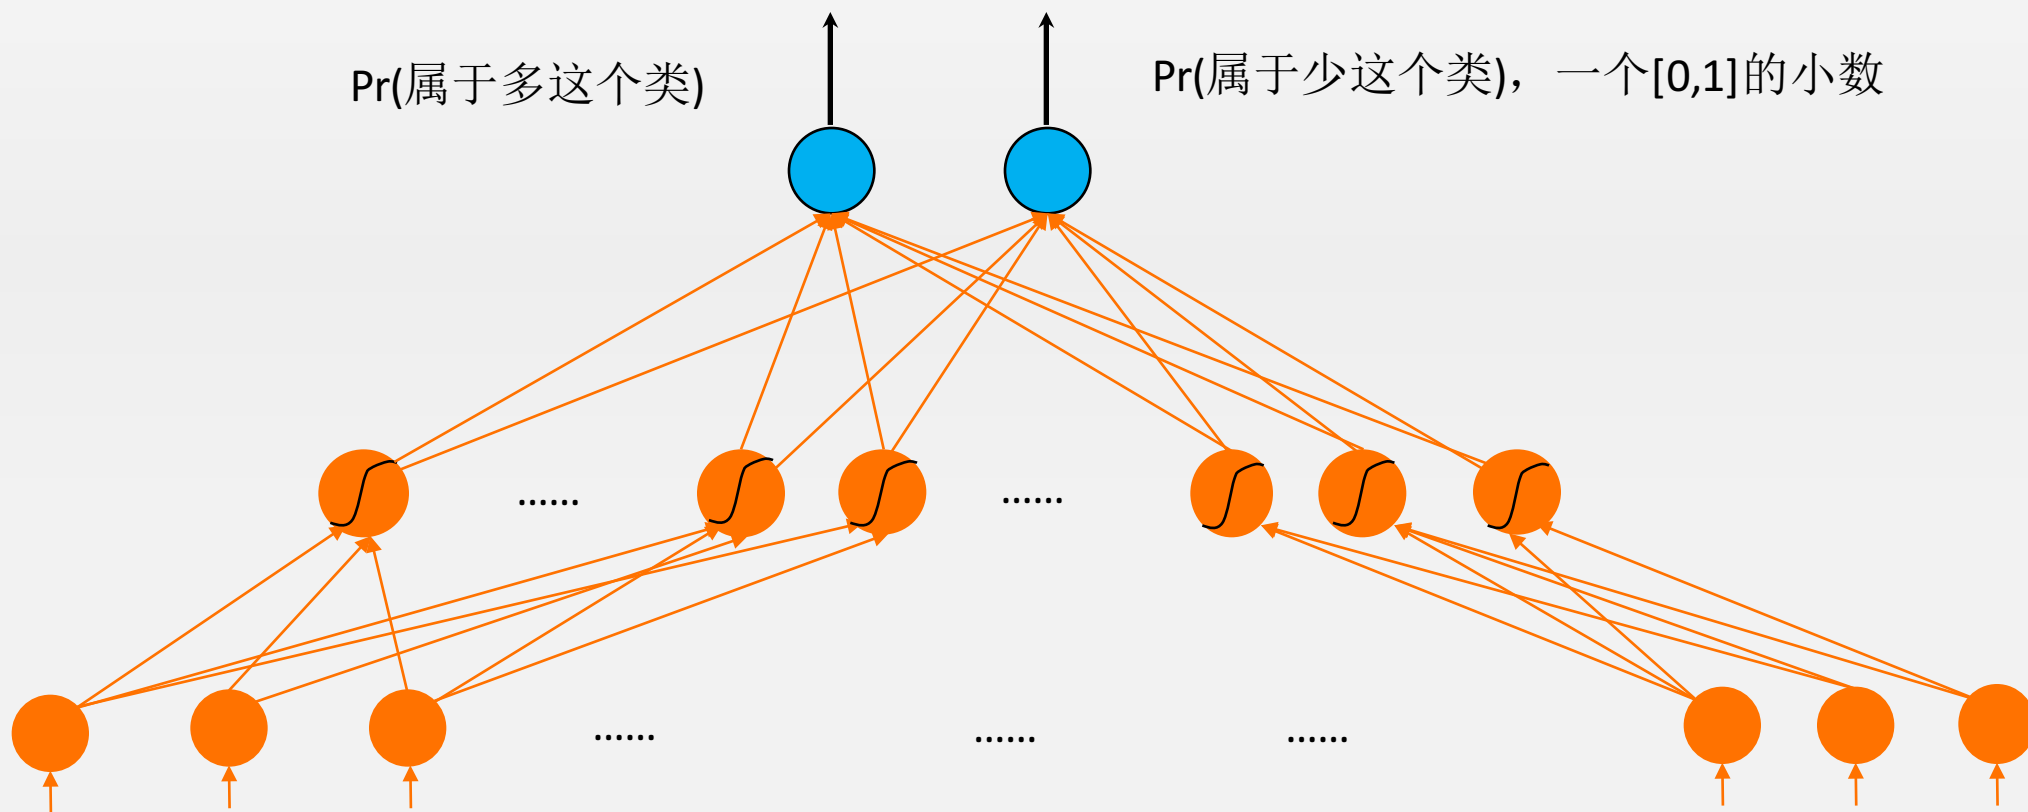
# 结论

- 预测不准是因为圣诞节假期的反常模式
- 在24号预测值偏高是因为对节假日抑制单元的抑制不够
- 由于圣诞节的缘故，22、23这两天的午高峰出行较少，甚至比一般节假日还少
- 解决：特殊日期的训练需要提供更多数据，或者手工调整权重



# 分类问题

- 并不预测单车数量，而是对数量做分类
- 分为两类：单车数量>均值的为多，<均值的为少



# 新的神经网络Neuc

```
input_size = features.shape[1]
hidden_size = 10
output_size = 2
batch_size = 128
neuc = torch.nn.Sequential(
    torch.nn.Linear(input_size, hidden_size),
    torch.nn.Sigmoid(),
    torch.nn.Linear(hidden_size, output_size),
    torch.nn.Sigmoid(),)
cost = torch.nn.CrossEntropyLoss()
optimizer = torch.optim.SGD(neuc.parameters(), lr = 0.1)
```

- 建立一个多步操作的神经网络模型
- 第一步从输入层到隐含层节点为一个线性运算，输入维度 `input_size`，隐含维度10
- 第二步为Sigmoid，作用到每一个隐含层神经元上
- 第三步又是一个线性运算，从隐含到输出，神经元个数分别为10和2，2为分类的类别数
- 第四步是一个Sigmoid，把输出结果变换为概率
- 所有神经网络的参数都存储在 `neuc.parameters()` 里面了
- 新建对于分类的损失函数 `cost`
- 新建优化器

# 交叉熵

- 交叉熵是一个用来衡量分类准确度的指标
- 它的计算公式为:

C为样本数量

$$L = - \sum_{i=1}^C \log \Pr(l(i))$$


l(i)为样本i的分类标签

# 主要训练循环


```
losses = []
errors = []
for i in range(2000):
    # 每128个样本点被划分为一个撮
    batch_loss = []
    batch_errors = []
    for start, end in zip(range(0, len(X), batch_size), range(batch_size, len(X)+1, batch_size)):
        xx = Variable(torch.FloatTensor(X[start:end]))
        yy = Variable(torch.LongTensor(Y_labels[start:end]))
        predict = neuc(xx)
        loss = cost(predict, yy)
        err = error_rate(predict.data.numpy(), yy.data.numpy()) #计算当前batch中的错误率%，自定义函数
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
        batch_loss.append(loss.data.numpy())
        batch_errors.append(err)
    # 每隔100步输出一下损失值（loss）
    if i % 100 == 0:
        losses.append(np.mean(batch_loss))
        errors.append(np.mean(batch_errors))
    print(i, np.mean(batch_loss), np.mean(batch_errors))
```



# 训练结果



测试集上的平均错误率: 13.7%



# 今日回顾









- 人工神经网络的工作原理
- 如何用人工神经网络来做预测
- 初始化权重范围的重要性
- 如何分析一个训练好的人工神经网络
- 运用神经网络进行分类的基本原理
  
- PyTorch中构建序列化神经网络的方法
- 理解MSELoss和CrossEntropyLoss

# 练习与作业

- 练习（不需要上交）：
  - 实现一个三分类网络，对自行车预测数据进行高、中、低这三个类别的划分
- 作业：
  - 在minstClassifier.ipynb的基础上实现一个对手写数字进行分类的多层人工神经网络

# 关于作业

Labels: 0, 1, ....., 9



注意事项:

- 可考虑多层神经网络
- 可考虑其它激活函数, 如Tanh, ReLu  
效果更好

$$\begin{bmatrix} 3 & \dots & 2 \\ \vdots & \ddots & \vdots \\ 2.1 & \dots & 1 \end{bmatrix} \quad \begin{bmatrix} 3 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 2.1 & \dots & 1 \end{bmatrix} \quad \begin{bmatrix} 3 & \dots & 2 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}$$

## 下次内容

